Mahidol University
Wisdom of the Land

Mahidol University

Lecture 15: Numpy and Pandas

Lecturers:

Aj. Jidapa Kraisangka

Aj. Akara Supratak

Aj. Suradej Intagorn

```
import numpy as np
```

- เป็นหนึ่งใน Python library ที่ใช้สำหรับการประมวลผลข้อมูลอาเรย์หลายมิติ (n-D array)
- อาเรย์ (array) นิยมใช้สำหรับเก็บข้อมูลประเภทเดียวกันแบบเป็นลำดับได้
- การคำนวนทางคณิตศาสตร์จะทำได้เร็วมาก ควรใช้ของ NumPy ในการคำนวน ไม่ควรเขียนเอง

การสร้าง numpy array


```
import numpy as np
arr = np.array([1, 2, 3, 4, 5])
print(arr)
print(type(arr))
```

```
[1 2 3 4 5]
<class 'numpy.ndarray'>
```

0-D Array

```
import numpy as np
arr = np.array(42)  # 0-D array
print(arr)
```

```
42
```

การสร้าง numpy array มิติต่างๆ

1-D Array

```
import numpy as np
arr = np.array([1, 2, 3, 4, 5])  # 1-D array
print(type(a))
print(a.shape)
print(a[0], a[1], a[2])  # index
```

จะให้ค่าจำนวน element ในแต่ละมิติของ array มาในรูปแบบของ tuple

```
[1 2 3 4 5]
1 2 3
<class 'numpy.ndarray'>
(5,)
```

2-D Array

```
import numpy as np
arr = np.array([[1,2,3], [4,5,6]])
print(arr)
print(arr[0,0], arr[0,1], arr[1,0], arr[-1,-1])  # index
print(arr.shape)
```

```
[[1 2 3]
 [4 5 6]]
1 2 4 6
(2, 3)
```

Array Slicing


```
import numpy as np
a = np.array([
  [1,2,3,4],
  [5,6,7,8],
  [9,10,11,12]
])
print(a)
# ดึง 2-D array จาก a ที่แถวที่ 0 และ 1 หลักที่ 1 และ 2
b = a[:2, 1:3]
print(b)
```

```
[[ 1  2  3  4]
 [ 5  6  7  8]
 [ 9 10 11 12]]
[[2 3]
 [6 7]]
```

Array Slicing

การใช้ slicing จะไม่ทำให้มิติ (dimension) ของ numpy array ลดลง

```
import numpy as np
# 2D array of shape (3,4)
a = np.array([[1,2,3,4], [5,6,7,8], [9,10,11,12]])
print(a)

row_r1 = a[1, :]     # มิติลดลงถ้าเราใช้ตัวเลข integer
row_r2 = a[1:2, :]   # มิติเท่าเดิม
print(row_r1, row_r1.shape)
print(row_r2, row_r2.shape)
```

```
[[ 1  2  3  4]
 [ 5  6  7  8]
 [ 9 10 11 12]]
[5 6 7 8] (4,)
[[5 6 7 8]] (1, 4)
```

Boolean array indexing

เราสามารถเข้าถึง element ตามเงื่อนไข (condition) ต่าง ๆ ได้

```
import numpy as np
a = np.array([[1,2], [3, 4], [5, 6]])
bool_idx = (a > 2)   # จะได้ boolean array ที่มีจำนวนมิติเท่ากัน
                     # โดยแต่ละ element เป็น True หรือ False
                     # ที่แสดงสถานะว่า element นั้นเป็นไปตาม
                     # เงื่อนไขที่กำหนดหรือไม่
print(bool_idx)

# เราสามารถเข้าถึง element ต่างโดยใช้ boolean array ได้
# โดยจะดึงมาเฉพาะ element ที่เป็น True เท่านั้น
print(a[bool_idx])
```

```
[[False False]
 [ True  True]
 [ True  True]]
[3 4 5 6]
```

เปลี่ยน dtype ใน numpy

เราสามารถใช้คำสั่ง `astype` ในการเปลี่ยนประเภทของข้อมูลใน numpy array ได้

```
import numpy as np
arr = np.array([1.1, 2.1, 3.1])
print(arr)
print(arr.dtype)
newarr = arr.astype(int)
print(newarr)
print(newarr.dtype)
newarr = newarr.astype(float)
print(newarr)
print(newarr.dtype)
```

```
[1.1 2.1 3.1]
float64
[1 2 3]
int64
[1. 2. 3.]
float64
```

Math functions in NumPy


```
import numpy as np
arr1 = np.array([10, 11, 12, 13, 14, 15])
arr2 = np.array([20, 21, 22, 23, 24, 25])

out = np.add(arr1, arr2)
# arr1 + arr2 (element-wise)
print(out)
out = np.subtract(arr1, arr2)
# arr1 - arr2 (element-wise)
print(out)
out = np.multiply(arr1, arr2)
print(out)
out = np.divide(arr1, arr2)
print(out)
```

```
[30 32 34 36 38 40]
[-10 -10 -10 -10 -10 -10]
[200 231 264 299 336 375]
[0.5        0.52380952 0.54545455
0.56521739 0.58333333 0.6       ]
```

Math functions in NumPy


```
import numpy as np
arr = np.array([[1,2,3], [4,5,6]])

# หาผลรวมตามมิติแรก
out = np.sum(arr, axis=0)
print(out)

# หาผลรวมตามมิติที่สอง
out = np.sum(arr, axis=1)
print(out)
```

```
[5 7 9]
[ 6 15]
```

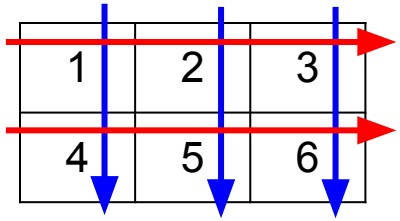

สามารถทำได้เหมือนกันกับ

`mean()` → หาค่าเฉลี่ย

`std()` → หาค่าเบี่ยงเบนมาตรฐาน

ดูเพิ่มเติมที่

https://www.w3schools.com/python/numpy/numpy_ufunc.asp

ตัวอย่าง

รับค่ามาใส่ 2D array โดยใช้ `input()`

```
import numpy as np

# Number of rows and columns
n_rows, n_cols = input().split(' ')
n_rows, n_cols = int(n_rows), int(n_cols)
rows = []
for r in range(n_rows):
    values = input().strip().split(' ')
    rows.append(np.array(values))
input_matrix = np.array(rows, dtype=np.int8)
print(input_matrix, type(input_matrix), input_matrix.dtype)
```

```
2 3
1 2 3
4 5 6
[[1 2 3]
 [4 5 6]] <class 'numpy.ndarray'> int8
```

ตัวอย่าง

อ่านค่าจากไฟล์ sample_matrix.txt มาใส่ 2D array

```
import numpy as np
with open('sample_matrix.txt', 'r') as f:
    lines = f.readlines()
    n_rows, n_cols = lines[0].split(' ')
    n_rows, n_cols = int(n_rows), int(n_cols)
    rows = []
    for l in lines[1:]:
        values = l.split(' ')
        rows.append(values)
input_matrix = np.array(rows, dtype=np.int8)
print(n_rows, n_cols, input_matrix.shape)
print(input_matrix)
print(type(input_matrix), input_matrix.dtype)
```

sample_matrix.txt

```
4 5
1 2 3 4 5
6 7 8 9 10
11 12 13 14 15
-5 -4 -3 -2 -1
```

```
4 5 (4, 5)
[[ 1  2  3  4  5]
 [ 6  7  8  9 10]
 [11 12 13 14 15]
 [-5 -4 -3 -2 -1]]
<class 'numpy.ndarray'> int8
```

ตัวอย่าง

แสดงค่าใน 2D array ที่มีค่ามากกว่า 10 และคำนวนหาผมรวมของค่าเหล่านั้น

```
import numpy as np
x = np.array([[0, 10, 20], [20, 30, 40]])
print(x)

# แสดงผล
print(x[x>10])

# หาผลรวม
print(np.sum(x[x>10]))
```

```
[[ 0 10 20]
 [20 30 40]]
[20 20 30 40]
110
```

อ่านเพิ่มเติมเกี่ยวกับ NumPy

Reference: https://numpy.org/doc/stable/reference/

Exercise: https://www.w3resource.com/python-exercises/numpy/

•

pandas

การติดตั้ง Pandas

เราสามารถทำการติดตั้ง pandas ด้วยคำสั่งด้านล่าง

```
pip install pandas
```

ความจำเป็นของ Pandas

- ถูกสร้างขึ้นมาเพื่อประมวลผลข้อมูลขนาดใหญ่ (Big Data) ที่เป็นตาราง (Tabular Data)
  - read_excel: Microsoft Excel
  - read_csv: CSV file
  - read_json: JSON file or JSON string
  - read_sql: SQL query or database table
  - ...
- Pandas เก็บและประมวลผลข้อมูลตารางผ่าน Series หรือ DataFrame

สร้างผ่าน dict

```
import pandas as pd

data = {
  "calories": [420, 380, 390],
  "duration": [50, 40, 45]
}

df = pd.DataFrame(data)

print(df)
```

สร้างผ่าน dict

```
import pandas as pd

data = {
  "calories": [420, 380, 390],
  "duration": [50, 40, 45]
}

df = pd.DataFrame(data)

print(df)
```

ต้องมีขนาดเท่ากัน !!

สร้างผ่าน dict

```
import pandas as pd

data = {
  "calories": [420, 380, 390],
  "duration": [50, 40, 45]
}

df = pd.DataFrame(data)

print(df)
```

ชื่อคอลัมน์

ต้องมีขนาดเท่ากัน !!

สร้างผ่าน dict

ชื่อคอลัมน์

```
import pandas as pd

data = {
  "calories": [420, 380, 390],
  "duration": [50, 40, 45]
}

df = pd.DataFrame(data)

print(df)
```

ต้องมีขนาดเท่ากัน !!

```
   calories  duration
0       420        50
1       380        40
2       390        45
```

อ่านข้อมูลจากไฟล์ Comma-separated Value (CSV)

```
import pandas as pd

df = pd.read_csv('data.csv')
print(df)
```

```
     Unnamed: 0  PassengerId  Survived  Pclass  ...            Ticket      Fare        Cabin  Embarked
0             0            1         0       3  ...         A/5 21171    7.2500          UNK         S
1             1            2         1       1  ...          PC 17599   71.2833          C85         C
2             2            3         1       3  ...  STON/O2. 3101282    7.9250          UNK         S
3             3            4         1       1  ...            113803   53.1000         C123         S
4             4            5         0       3  ...            373450    8.0500          UNK         S
5             5            6         0       3  ...            330877    8.4583          UNK         Q
6             6            7         0       1  ...             17463   51.8625          E46         S
7             7            8         0       3  ...            349909   21.0750          UNK         S
```

แสดงข้อมูลใน DataFrame

```
import pandas as pd

df = pd.read_csv('data.csv')
print(df.head())
print(df.tail())
print(df.info())
```

แสดงข้อมูลใน DataFrame

```
import pandas as pd

df = pd.read_csv('data.csv')
print(df.head())
print(df.tail())
print(df.info())
```

```
   Unnamed: 0  PassengerId  Survived  Pclass  ...            Ticket     Fare  Cabin  Embarked
0           0            1         0       3  ...         A/5 21171   7.2500    UNK         S
1           1            2         1       1  ...          PC 17599  71.2833    C85         C
2           2            3         1       3  ...  STON/O2. 3101282   7.9250    UNK         S
3           3            4         1       1  ...            113803  53.1000   C123         S
4           4            5         0       3  ...            373450   8.0500    UNK         S

[5 rows x 13 columns]
     Unnamed: 0  PassengerId  Survived  Pclass  ...      Ticket   Fare  Cabin  Embarked
886         886          887         0       2  ...      211536  13.00    UNK         S
887         887          888         1       1  ...      112053  30.00    B42         S
888         888          889         0       3  ...  W./C. 6607  23.45    UNK         S
889         889          890         1       1  ...      111369  30.00   C148         C
890         890          891         0       3  ...      370376   7.75    UNK         Q

[5 rows x 13 columns]
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 13 columns):
Unnamed: 0     891 non-null int64
PassengerId    891 non-null int64
Survived       891 non-null int64
Pclass         891 non-null int64
Name           891 non-null object
Sex            891 non-null object
Age            891 non-null float64
SibSp          891 non-null int64
Parch          891 non-null int64
Ticket         891 non-null object
Fare           891 non-null float64
Cabin          891 non-null object
Embarked       891 non-null object
dtypes: float64(2), int64(6), object(5)
memory usage: 90.6+ KB
None
```

แสดงข้อมูลใน DataFrame

```
import pandas as pd

df = pd.read_csv('data.csv')
print(df.head())
print(df.tail())
print(df.info())
print(df.describe())
```

```
   Unnamed: 0  PassengerId  Survived  Pclass  ...            Ticket     Fare  Cabin  Embarked
0           0            1         0       3  ...         A/5 21171   7.2500    UNK         S
1           1            2         1       1  ...          PC 17599  71.2833    C85         C
2           2            3         1       3  ...  STON/O2. 3101282   7.9250    UNK         S
3           3            4         1       1  ...            113803  53.1000   C123         S
4           4            5         0       3  ...            373450   8.0500    UNK         S

[5 rows x 13 columns]
     Unnamed: 0  PassengerId  Survived  Pclass  ...      Ticket   Fare  Cabin  Embarked
886         886          887         0       2  ...      211536  13.00    UNK         S
887         887          888         1       1  ...      112053  30.00    B42         S
888         888          889         0       3  ...  W./C. 6607  23.45    UNK         S
889         889          890         1       1  ...      111369  30.00   C148         C
890         890          891         0       3  ...      370376   7.75    UNK         Q

[5 rows x 13 columns]
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 13 columns):
Unnamed: 0     891 non-null int64
PassengerId    891 non-null int64
Survived       891 non-null int64
Pclass         891 non-null int64
```

```
       Unnamed: 0  PassengerId    Survived      Pclass         Age       SibSp       Parch        Fare
count  891.000000   891.000000  891.000000  891.000000  891.000000  891.000000  891.000000  891.000000
mean   445.000000   446.000000    0.383838    2.308642   29.699118    0.523008    0.381594   32.204208
std    257.353842   257.353842    0.486592    0.836071   13.002015    1.102743    0.806057   49.693429
min      0.000000     1.000000    0.000000    1.000000    0.420000    0.000000    0.000000    0.000000
25%    222.500000   223.500000    0.000000    2.000000   22.000000    0.000000    0.000000    7.910400
50%    445.000000   446.000000    0.000000    3.000000   29.699118    0.000000    0.000000   14.454200
75%    667.500000   668.500000    1.000000    3.000000   35.000000    1.000000    0.000000   31.000000
max    890.000000   891.000000    1.000000    3.000000   80.000000    8.000000    6.000000  512.329200

None
```

ตัวอย่าง: แสดง PassengerId บางส่วน


```
import numpy as np
import pandas as pd

df = pd.read_csv('data.csv')
print(df.head(10)['PassengerId'].values)   # np.ndarray
print(df.iloc[:10]['PassengerId'])         # pd.Series

# NumPy กับ Pandas ถูกออกแบบมาให้ทำงานร่วมกันได้
print(np.sum(df.head(10)['PassengerId']))
print(np.sum(df.iloc[:10]['PassengerId'].values))
# สามารถใช้กับ function อื่นนอกจาก np.sum ได้เหมือนกัน
```

ใช้ระบุ index หรือทำ slicing เสมือนเป็น 2D array ได้ เช่น

```
.iloc[4,5]
.iloc[:,3:6]
```

ตัวอย่าง: แสดง PassengerId บางส่วน


```
import numpy as np
import pandas as pd

df = pd.read_csv('data.csv')
print(df.head(10)['PassengerId'].values)   # np.ndar
print(df.iloc[:10]['PassengerId'])         # pd.Seri

# NumPy กับ Pandas ถูกออกแบบมาให้ทำงานร่วมกันได้
print(np.sum(df.head(10)['PassengerId']))
print(np.sum(df.iloc[:10]['PassengerId'].values))
# สามารถใช้กับ function อื่นนอกจาก np.sum ได้เหมือนกัน
```

```
[ 1  2  3  4  5  6  7  8
9 10]
0     1
1     2
2     3
3     4
4     5
5     6
6     7
7     8
8     9
9    10
Name: PassengerId, dtype:
int64
55
55
```

แสดงเฉพาะข้อมูลคอลัมน์ PassengerId กับ Pclass

```
import pandas as pd

df = pd.read_csv('data.csv')
small_df = df.head(10)  # df.iloc[:10]
print(small_df[['PassengerId','Pclass']])
print(small_df[['PassengerId','Pclass']].values)
```

```
   PassengerId  Pclass
0            1       3
1            2       1
2            3       3
3            4       1
4            5       3
5            6       3
6            7       1
7            8       3
8            9       3
9           10       2
[[ 1  3]
 [ 2  1]
 [ 3  3]
 [ 4  1]
 [ 5  3]
 [ 6  3]
 [ 7  1]
 [ 8  3]
 [ 9  3]
 [10  2]]
```

แสดงเฉพาะผู้โดยสารที่มี Pclass==1

```
import pandas as pd

df = pd.read_csv('data.csv')
first_class_df = df[df['Pclass']==1]
print(first_class_df)
```

```
     Unnamed: 0  PassengerId  Survived  Pclass  ...       Ticket      Fare        Cabin  Embarked
1             1            2         1       1  ...     PC 17599   71.2833          C85         C
3             3            4         1       1  ...       113803   53.1000         C123         S
6             6            7         0       1  ...        17463   51.8625          E46         S
11           11           12         1       1  ...       113783   26.5500         C103         S
23           23           24         1       1  ...       113788   35.5000           A6         S
27           27           28         0       1  ...        19950  263.0000  C23 C25 C27         S
30           30           31         0       1  ...     PC 17601   27.7208          UNK         C
...
```

แสดงเฉพาะผู้โดยสารที่มี Sex เป็น 'male'

```
import pandas as pd


df = pd.read_csv('data.csv')
```

แสดงเฉพาะผู้โดยสารที่มี Sex เป็น 'male'

```
import pandas as pd


df = pd.read_csv('data.csv')
male_passenger_df = df[df['Sex']=='male']
print(male_passenger_df)
```

```
     Unnamed: 0  PassengerId  Survived  Pclass                          Name  ... Parch            Ticket     Fare  Cabin
Embarked
0             0            1         0       3         Braund, Mr. Owen Harris  ...     0         A/5 21171   7.2500    UNK
S
4             4            5         0       3        Allen, Mr. William Henry  ...     0            373450   8.0500    UNK
S
5             5            6         0       3                Moran, Mr. James  ...     0            330877   8.4583    UNK
Q
6             6            7         0       1         McCarthy, Mr. Timothy J  ...     0             17463  51.8625    E46
S
7             7            8         0       3  Palsson, Master. Gosta Leonard  ...     1            349909  21.0750    UNK
S
..          ...          ...       ...     ...                            ...  ...   ...               ...      ...    ...
...
883         883          884         0       2   Banfield, Mr. Frederick James  ...     0  C.A./SOTON 34068  10.5000    UNK
```

หาค่าเฉลี่ยอายุของผู้โดยสารที่มี Sex เป็น 'male'

```
import pandas as pd


df = pd.read_csv('data.csv')
```

หาค่าเฉลี่ยอายุของผู้โดยสารที่มี Sex เป็น 'male'

```
import pandas as pd
import numpy as np

df = pd.read_csv('data.csv')
male_passenger_df = df[df['Sex']=='male']
print(np.mean(male_passenger_df['Age']))
print(male_passenger_df['Age'].mean())
```

```
30.50582424304206
30.50582424304206
```

หาค่าเฉลี่ยอายุของผู้โดยสารผู้ชายและผู้หญิง

หาค่าเฉลี่ยอายุของผู้โดยสารผู้ชายและผู้หญิง

```
import pandas as pd
import numpy as np

df = pd.read_csv('data.csv')
male_passenger_df = df[df['Sex']=='male']
print(male_passenger_df['Age'].mean())
female_passenger_df = df[df['Sex']=='female']
print(female_passenger_df['Age'].mean())
```

```
30.50582424304206
28.216730048707397
```

เลือกข้อมูลผู้โดยสารที่มีชื่อบางส่วนเป็น James

```
import pandas as pd
import numpy as np

df = pd.read_csv('data.csv')
james_df = df[df['Name'].str.contains('James')]
print(james_df[['PassengerId', 'Name', 'Pclass', 'Embarked']])
```

เลือกข้อมูลผู้โดยสารที่มีชื่อบางส่วนเป็น James

```
import pandas as pd
import numpy as np

df = pd.read_csv('data.csv')
james_df =
df[df['Name'].str.contains('James')]
print(james_df[['PassengerId',
'Name', 'Pclass', 'Embarked']])
```

	PassengerId	Name	Pclass	Embarked
5	6	Moran, Mr. James	3	Q
67	68	Crease, Mr. Ernest James	3	S
134	135	Sobey, Mr. Samuel James Hayden	2	S
150	151	Bateman, Rev. Robert James	2	S
161	162	Watt, Mrs. James (Elizabeth "Bessie" Inglis Mi...	2	S
174	175	Smith, Mr. James Clinch	1	C
194	195	Brown, Mrs. James Joseph (Margaret Tobin)	1	C
221	222	Bracken, Mr. James H	2	S
250	251	Reed, Mr. James George	3	S
299	300	Baxter, Mrs. James (Helene DeLaudeniere Chaput)	1	C
416	417	Drew, Mrs. James Vivian (Lulu Thorne Christian)	2	S
428	429	Flynn, Mr. James	3	Q
468	469	Scanlan, Mr. James	3	Q
511	512	Webber, Mr. James	3	S
512	513	McGough, Mr. James Robert	1	S
525	526	Farrell, Mr. James	3	Q
551	552	Sharp, Mr. Percival James R	2	S
582	583	Downton, Mr. William James	2	S
592	593	Elsbury, Mr. William James	3	S
696	697	Kelly, Mr. James	3	S
740	741	Hawksford, Mr. Walter James	1	S
811	812	Lester, Mr. James	3	S
812	813	Slemen, Mr. Richard James	2	S
883	884	Banfield, Mr. Frederick James	2	S

เลือกข้อมูลผู้โดยสารที่มีชื่อบางส่วนเป็น James

```
import pandas as pd
import numpy as np

df = pd.read_csv('data.csv')
james_df =
df[df['Name'].str.contains('James')]
print(james_df[['PassengerId',
'Name', 'Pclass', 'Embarked']])
```

	PassengerId	Name	Pclass	Embarked
5	6	Moran, Mr. James	3	Q
67	68	Crease, Mr. Ernest James	3	S
134	135	Sobey, Mr. Samuel James Hayden	2	S
150	151	Bateman, Rev. Robert James	2	S
161	162	Watt, Mrs. James (Elizabeth "Bessie" Inglis Mi...	2	S
174	175	Smith, Mr. James Clinch	1	C
194	195	Brown, Mrs. James Joseph (Margaret Tobin)	1	C
221	222	Bracken, Mr. James H	2	S
250	251	Reed, Mr. James George	3	S
299	300	Baxter, Mrs. James (Helene DeLaudeniere Chaput)	1	C
416	417	Drew, Mrs. James Vivian (Lulu Thorne Christian)	2	S
428	429	Flynn, Mr. James	3	Q
468	469	Scanlan, Mr. James	3	Q
511	512	Webber, Mr. James	3	S
512	513	McGough, Mr. James Robert	1	S
525	526	Farrell, Mr. James	3	Q
551	552	Sharp, Mr. Percival James R	2	S
582	583	Downton, Mr. William James	2	S
592	593	Elsbury, Mr. William James	3	S
696	697	Kelly, Mr. James	3	S
740	741	Hawksford, Mr. Walter James	1	S
811	812	Lester, Mr. James	3	S
812	813	Slemen, Mr. Richard James	2	S
883	884	Banfield, Mr. Frederick James	2	S

มีชื่อ James เป็นส่วนหนึ่งก็ได้

เลือกข้อมูลผู้โดยสารที่ขึ้นเรือจากท่า 'Q' หรือ 'S'

```
import pandas as pd
import numpy as np

df = pd.read_csv('data.csv')
embark_df = df[df['Embarked'].isin(['Q','S'])]
print(embark_df[['PassengerId', 'Name', 'Pclass', 'Embarked']])
```

เลือกข้อมูลผู้โดยสารที่ขึ้นเรือจากท่า 'Q' หรือ 'S'

```
import pandas as pd
import numpy as np

df = pd.read_csv('data.csv')
embark_df = df[df['Embarked'].isin(['Q','S'])]
print(embark_df[['PassengerId', 'Name', 'Pclass', 'Embarked']])
```

ต้องเป็น list หรือ numpy array ของค่า

เลือกข้อมูลผู้โดยสารที่ขึ้นเรือจากท่า 'Q' หรือ 'S'

มีค่าเท่ากับ 'Q' หรือ 'S' เท่านั้น

```
import pandas as p
import numpy as np

df = pd.read_csv('data.csv')
embark_df =
df[df['Embarked'].isin(['Q','S'
])]
print(embark_df[['PassengerId',
'Name', 'Pclass', 'Embarked']])
```

```
     PassengerId                                          Name  Pclass Embarked
0              1                       Braund, Mr. Owen Harris       3        S
2              3                        Heikkinen, Miss. Laina       3        S
3              4  Futrelle, Mrs. Jacques Heath (Lily May Peel)       1        S
4              5                      Allen, Mr. William Henry       3        S
5              6                              Moran, Mr. James       3        Q
..           ...                                           ...     ...      ...
885          886          Rice, Mrs. William (Margaret Norton)       3        Q
886          887                         Montvila, Rev. Juozas       2        S
887          888                  Graham, Miss. Margaret Edith       1        S
888          889      Johnston, Miss. Catherine Helen "Carrie"       3        S
890          891                          Dooley, Mr. Patrick       3        Q

[721 rows x 4 columns]
```

ไม่ควรใช้ `isin` ถ้าเราจะอนุญาติให้เหมือนกันแค่บางส่วนของ string (substring)

```
import pandas as pd
import numpy as np

df = pd.read_csv('data.csv')
james_df = df[df['Name'].isin(['James'])]
print(james_df [['PassengerId', 'Name', 'Pclass', 'Embarked']])
```

ไม่ควรใช้ `isin` ถ้าเราจะอนุญาติให้เหมือนกันแค่บางส่วนของ string (substring)

```
import pandas as pd
import numpy as np

df = pd.read_csv('data.csv')
james_df = df[df['Name'].isin(['James'])]
print(james_df [['PassengerId', 'Name', 'Pclass', 'Embarked']])
```

ไม่มีผู้โดยสารที่มีชื่อตรงกับ 'James'

```
Empty DataFrame
Columns: [PassengerId, Name, Pclass, Embarked]
Index: []
```

นับจำนวนของค่าในคอลัมน์ : value_counts()

```
import pandas as pd

df = pd.read_csv('data.csv')
print(df['Embarked'].value_counts())            # pd.Series
print(df['Embarked'].value_counts().to_dict())  # dict
```

```
S      644
C      168
Q       77
UNK      2
Name: Embarked, dtype: int64
{'S': 644, 'C': 168, 'Q': 77, 'UNK': 2}
```

หาค่าที่ไม่ซ้ำกันในแต่ละคอลัมน์ : unique()

```
import pandas as pd

df = pd.read_csv('data.csv')
print(df['Pclass'].unique())     # numpy array
print(df['Embarked'].unique())   # numpy array

# ระวัง: ไม่ควรใช้กับตัวเลขจำนวนจริง (ที่จะมีค่าแตกต่างกันเยอะมาก) เช่น ค่าโดยสาร
# print(df['Fare'].unique())
```

```
[3 1 2]
['S' 'C' 'Q' 'UNK']
```

เรียงลำดับโดยดูจากค่าในคอลัมน์ต่าง ๆ : sort_values()

```
import pandas as pd

df = pd.read_csv('data.csv')
print(df.sort_values(by=['Pclass']))                    #ค่าตั้งต้นมาตรฐาน ascending=True (เรียงจากน้อยไปมาก)
print(df.sort_values(by=['Pclass'], ascending=False))   #เรียงจากมากไปน้อย
```

เรียงลำดับโดยดูจากค่าในคอลัมน์ต่าง ๆ : sort_values()

```
import pandas as pd

df = pd.read_csv('data.csv')
print(df.sort_values(by=['Pclass']))                    #ค่าตั้งต้นมาตรฐาน ascending=True (เรียงจากน้อยไปมาก)
print(df.sort_values(by=['Pclass'], ascending=False))   #เรียงจากมากไปน้อย

# เรียงด้วย Pclass จากมากไปน้อยตามด้วย Fare จากมากไปน้อย
print(df.sort_values(by=['Pclass', 'Fare'], ascending=False)[['Pclass', 'Fare']])

# เรียงด้วย Pclass จากน้อยไปมากตามด้วย Fare จากมากไปน้อย
print(df.sort_values(by=['Pclass', 'Fare'], ascending=[True, False])[['Pclass', 'Fare']])
```

เราสามารถรวมเงื่อนไขต่าง ๆ ได้โดยใช้

- & : and
- | : or
- ~ : not

แสดงผู้โดยสารผู้ชายที่ซื้อตั๋วโดยสารถูกกว่า 15.25

```
import pandas as pd

df = pd.read_csv('data.csv')
print(df[(df['Sex']=='male') & (df['Fare']<15.25)])
```

แสดงผู้โดยสารผู้ชายที่ซื้อตั๋วโดยสารถูกกว่า 15.25

```
import pandas as pd
```

ต้องมีวงเล็บ () ครอบเงื่อนไขต่าง ๆ เวลาที่ถูกเชื่อมด้วย &, | หรือ ~ ด้วย

```
df = pd.read_csv('data.csv')
print(df[(df['Sex']=='male') & (df['Fare']<15.25)])
```

ผู้โดยสารผู้ชาย

ค่าตั๋วถูกกว่า 15.25

```
     Unnamed: 0  PassengerId  Survived  Pclass                          Name   Sex       Age  SibSp  Parch            Ticket    Fare Cabin Embarked
0             0            1         0       3        Braund, Mr. Owen Harris  male  22.000000      1      0         A/5 21171  7.2500   UNK        S
4             4            5         0       3       Allen, Mr. William Henry  male  35.000000      0      0            373450  8.0500   UNK        S
5             5            6         0       3               Moran, Mr. James  male  29.699118      0      0            330877  8.4583   UNK        Q
12           12           13         0       3  Saundercock, Mr. William Henry  male  20.000000      0      0         A/5. 2151  8.0500   UNK        S
17           17           18         1       2    Williams, Mr. Charles Eugene  male  29.699118      0      0            244373 13.0000   UNK        S
..          ...          ...       ...     ...                           ...   ...       ...    ...    ...               ...     ...   ...      ...
881         881          882         0       3              Markun, Mr. Johann  male  33.000000      0      0            349257  7.8958   UNK        S
883         883          884         0       2   Banfield, Mr. Frederick James  male  28.000000      0      0  C.A./SOTON 34068 10.5000   UNK        S
884         884          885         0       3          Sutehall, Mr. Henry Jr  male  25.000000      0      0   SOTON/OQ 392076  7.0500   UNK        S
886         886          887         0       2           Montvila, Rev. Juozas  male  27.000000      0      0            211536 13.0000   UNK        S
890         890          891         0       3             Dooley, Mr. Patrick  male  32.000000      0      0            370376  7.7500   UNK        Q

[349 rows x 13 columns]
```

แสดงผู้โดยสารผู้ชายที่ซื้อตั๋วโดยสารถูกกว่า 15.25

```
import pandas as pd

df = pd.read_csv('data.csv')
sel_df = df[(df['Sex']=='male') & (df['Fare']<15.25)]

# เรียงตามราคาตั๋ว
sel_df = sel_df.sort_values(by=['Fare'], ascending=False)

# แสดงผลเฉพาะคอลัมน์ 'Name','Sex','Fare'
print(sel_df[['Name','Sex','Fare']])
```

แสดงผู้โดยสารผู้ชายที่ซื้อตั๋วโดยสารถูกกว่า 15.25

```
import pandas as pd

df = pd.read_csv('data.csv')
sel_df = df[(df['Sex']=='male') & (df['Fare']<15.25)]

# เรียงตามราคาตั๋ว
sel_df = sel_df.sort_values(by=['Fare'], ascending=False)

# แสดงผลเฉพาะคอลัมน์ 'Name','Sex','Fare'
print(sel_df[['Name','Sex','Fare']])
```

```
                                                Name   Sex     Fare
65                              Moubarek, Master. Gerios  male  15.2458
709  Moubarek, Master. Halim Gonios ("William George")  male  15.2458
497                     Shellard, Mr. Frederick William  male  15.1000
181                                Pernot, Mr. Rene  male  15.0500
135                                Richard, Mr. Emile  male  15.0458
..                                                ...   ...      ...
263                            Harrison, Mr. William  male   0.0000
271                       Tornquist, Mr. William Henry  male   0.0000
277                        Parkes, Mr. Francis "Frank"  male   0.0000
302                     Johnson, Mr. William Cahoone Jr  male   0.0000
732                                Knight, Mr. Robert J  male   0.0000

[349 rows x 3 columns]
```

จำนวนผู้โดยสารผู้ชายและผู้หญิงที่ไม่ได้ขึ้นเรือจากท่า 'S'

```
import pandas as pd

df = pd.read_csv('data.csv')
sel_df = df[~df['Embarked'].isin(['S'])]
```

จำนวนผู้โดยสารผู้ชายและผู้หญิงที่ไม่ได้ขึ้นเรือจากท่า 'S'

```
import pandas as pd

df = pd.read_csv('data.csv')
sel_df = df[~df['Embarked'].isin(['S'])]
print(sel_df)
print(sel_df['Sex'].value_counts())
```

```
     Unnamed: 0  PassengerId  Survived  Pclass                                            Name     Sex  ...  SibSp  Parch    Ticket     Fare  Cabin Embarked
1             1            2         1       1  Cumings, Mrs. John Bradley (Florence Briggs Th...  female  ...      1      0  PC 17599  71.2833    C85        C
5             5            6         0       3                                  Moran, Mr. James    male  ...      0      0    330877   8.4583    UNK        Q
9             9           10         1       2                Nasser, Mrs. Nicholas (Adele Achem)  female  ...      1      0    237736  30.0708    UNK        C
16           16           17         0       3                               Rice, Master. Eugene    male  ...      4      1    382652  29.1250    UNK        Q
19           19           20         1       3                           Masselmani, Mrs. Fatima  female  ...      0      0      2649   7.2250    UNK        C
..          ...          ...       ...     ...                                               ...     ...  ...    ...    ...       ...      ...    ...      ...
875         875          876         1       3                   Najib, Miss. Adele Kiamie "Jane"  female  ...      0      0      2667   7.2250    UNK        C
879         879          880         1       1      Potter, Mrs. Thomas Jr (Lily Alexenia Wilson)  female  ...      0      1     11767  83.1583    C50        C
885         885          886         0       3               Rice, Mrs. William (Margaret Norton)  female  ...      0      5    382652  29.1250    UNK        Q
889         889          890         1       1                              Behr, Mr. Karl Howell    male  ...      0      0    111369  30.0000   C148        C
890         890          891         0       3                                Dooley, Mr. Patrick    male  ...      0      0    370376   7.7500    UNK        Q

[247 rows x 13 columns]
male      136
female    111
Name: Sex, dtype: int64
```